

组会汇报：GC-OPD (Group-Calibrated On-Policy Distillation)

Paper Read Skill

2026 年 9 月 17 日

目录

1	一句话贡献	2
2	任务定义与动机剖析	2
2.1	任务	2
2.2	问题与动机	2
2.3	现有局限	2
2.4	例子	2
3	方法论树状拆解	2
4	算法流程与公式细节推演	3
5	实验设定与资源开销	3
6	实验结论的因果支撑	3
7	复现前置准备清单	3
8	Paper 与代码缺口 / 开放问题	4

论文: Zhang, Wang et al. *Beyond Teacher Likelihood: Group-Calibrated On-Policy Distillation for Long-Context Reasoning*. arXiv:2608.19181v1. 代码: <https://github.com/SolereZhang/GC-OPD>. PDF: docs/3_GC-OPD.pdf。

1 一句话贡献

长上下文中教师 token 偏好会与任务验证器分歧。GC-OPD 不改教师前向，只在每个 rollout 组内分别对验证器奖励和轨迹级 OPD 分做 z -score，取其差作为有符号残差，再用 RACA 按相对 OPD 优势摊到 token 上，加回原始稠密 OPD 优势。

2 任务定义与动机剖析

2.1 任务

Qwen3-4B/8B (no-thinking) 的长上下文 OPD 后训练。教师 Qwen3-30B-A3B-Thinking-2507 只对学生已采样 token 给 logprob。训练 GoLongRL 滤到 $\leq 32K$ ，共 9527 prompt。评测 DocMath、Frames、MRCR、CorpusQA、LBv1QA 未加权平均。

2.2 问题与动机

Token 优势 $A_t = \log \pi_T - \log \pi_{\theta_{old}}$ 的期望是负 reverse-KL，测教师偏好而非任务成功。长输入上学生更易写出局部通顺但漏证据的回答。固定 8 条回答的诊断：MTE 的 pairwise disagreement 从 $<8K$ 的 40.6% 升到 32–64K 的 64.0%，OPD preference gap 从 +0.35 降到 -0.37；HRR 类似。更长时 OPD 开始更支持验证器更差的回答。

2.3 现有局限

ExOPD/PowerOPD/FiRe-OPD 改教师信号几何但不显式对比验证器；SCOPE/MOPD 路由或加权轨迹，易丢掉 graded 间距或原始 A_t ；Uni-OPD 做类间 margin；过程监督需要步标签。本文要保留 graded 组内差异，并把轨迹分歧变成 token 依赖校正。

2.4 例子

回答 A 漏表但教师喜欢 ($\tilde{R} = -0.8, \tilde{s} = +1.1$), $\rho = -1.9$; 回答 B 抽全了表 ($\tilde{R} = +0.8, \tilde{s} = -0.4$), $\rho = +1.2$ 。Vanilla OPD 推 A；残差压 A、抬 B。 $\beta = 0.10$ 使校正保持为校准。

3 方法论树状拆解

GC-OPD

```
|-- 1 组内相对评估 (教师 pass 不变)
|   At; s=mean At; R; 分别 z-score
|-- 2 残差 rho = Rtilde - stilde
|   减去 OPD 已表达的相对偏好; sigma 过小则 rho=0
`-- 3 RACA
```

```

ut=(At-s)/sigmaA; ct=1+tanh(ut/2) in (0,2)
A' = At + beta * ct * rho; clip [-10,10]

```

$\beta = 0$ 精确等于 vanilla OPD。

4 算法流程与公式细节推演

轨迹分与残差 (paper Eq. (3),(6),(7)):

$$s^{(i)} = \frac{1}{T^{(i)}} \sum_t A_t^{(i)}, \quad (1)$$

$$\tilde{R}^{(i)} = z(R^{(i)}), \quad \tilde{s}^{(i)} = z(s^{(i)}), \quad \rho^{(i)} = \tilde{R}^{(i)} - \tilde{s}^{(i)}. \quad (2)$$

若 $R^{(i)} > R^{(j)}$ 但 $s^{(i)} < s^{(j)}$, 则 $\rho^{(i)} - \rho^{(j)} > 0$ (paper Eq. (8)). RACA (paper Eq. (9)–(11)):

$$u_t^{(i)} = \frac{A_t^{(i)} - s^{(i)}}{\sigma_A^{(i)} + \epsilon}, \quad (3)$$

$$c_t^{(i)} = 1 + \tanh(u_t^{(i)}/2), \quad (4)$$

$$A_t'^{(i)} = A_t^{(i)} + \beta c_t^{(i)} \rho^{(i)}. \quad (5)$$

信用恒正, 只缩放不反转 ρ 的符号。守卫: $\tau_G = \tau_T = 10^{-6}$, $a_{\max} = 10$ 。无额外师生前向。

5 实验设定与资源开销

对照: Raw、OPD、ExOPD[†]、Uni-OPD[†]、PowerOPD[†]、FiRe-OPD[†] (共享 100 step 配方的机制移植)。 β 在 231 条 High-Recall holdout 上选为 0.10, 不当下游评测。配置: 32 prompt/step, $G = 8$, prompt 32768, response 10240, lr 10^{-6} , 硬件 $8 \times 80\text{GB H800/H100}$ 。评测 YaRN scale 4。

6 实验结论的因果支撑

主表 Avg: 4B 上 Raw 29.08、OPD 39.31、GC-OPD **40.47**; 8B 上 35.12、43.56、**44.65**。增益集中在 CorpusQA 等证据聚合 (中强支撑)。信号消融 (8B): 再加一份 OPD 仅 +0.04; 直接加 $\tilde{R}$ 为 +0.63; 残差 ρ 为 +1.10 (强支撑残差设计)。Token 分配: Uniform +0.72, RACA +1.10, Absolute $|A|$ 仅 +0.38。限制: 无多种子; β 单任务选; [†] baseline 非原配方。

7 复现前置准备清单

- 数据: Kwai-Klear/GoLongRL; scripts/prepare_golongrl_32k.py 应得 9527/231。
- 权重: Qwen3-4B/8B 与 Qwen3-30B-A3B-Thinking-2507。
- 环境: Python 3.12, CUDA 12.8, torch 2.10, vLLM 0.17。
- 入口: `bash scripts/run_gc_opd_4b_training.sh`; OPD 对照 `beta=0`。
- Sanity: 组内 R 全相同则 $\rho = 0$ 。

8 Paper 与代码缺口 / 开放问题

仓库与论文主设定对齐: $\beta = 0.10$, 核心在 `verl/trainer/ppo/gc_opd.py`。开放: thinking 学生; 与 TGOPD 门叠加时门关则无教师 s 。