

组会汇报：RLCSD (Contrastive On-Policy Self-Distillation)

Paper Read Skill

2026 年 9 月 17 日

目录

1	一句话贡献	2
2	任务定义与动机剖析	2
2.1	任务	2
2.2	问题与动机	2
2.3	现有局限	2
2.4	例子	2
3	方法论树状拆解	2
4	算法流程与公式细节推演	3
5	实验设定与资源开销	3
6	实验结论的因果支撑	3
7	复现前置准备清单	3
8	Paper 与代码缺口 / 开放问题	4

论文: Pan et al. *RLCSD: Reinforcement Learning with Contrastive On-Policy Self-Distillation*. arXiv:2606.11709v1. 代码: <https://github.com/THU-BPM/RLCSD>. PDF: docs/9.4_RLCSD.pdf. 超参以 PDF 附录 Table 8 为组会主口径。

1 一句话贡献

OPSD 的单侧特权信号 $e_{c,t}$ 会把梯度堆到 style token 上。RLCSD 在同一模板下用正确 hint 对 K 条错误 hint 做对比得到 $e_{ctr,t}$, squash 后只调制 A_{ORM} 的幅度, 并用 two-path 损失避免被未选中 token 稀释。

2 任务定义与动机剖析

2.1 任务

特权上下文自蒸馏: 师生同一模型, 教师多看参考解答。Thinking 模式。Qwen3-1.7B/4B/8B 与 Olmo-3-7B-Think。数学: DeepMath 分难度; AMC23/AIME24/AIME25 的 mean@12。逻辑: Knights & Knaves, ID 4-8 与 OOD 9/10/11 的 pass@1。

2.2 问题与动机

$$e_{c,t} = \log \pi_T(y_t | x, y_c^*, y_{<t}) - \log \pi_S(y_t | x, y_{<t}). \quad (1)$$

特权会锐化任务 token, 也带来更短、更武断、少探索的文风, 称为 privilege-induced style drift。数学上 $|e_c|$ 的 style 均值 0.263 对 task 0.083。OPSD/SDPO/SRPO 出现熵与长度爆炸; RLSD 出现数学长度收缩。

2.3 现有局限

上述 OPSD 变体都只用单侧正特权。GRPO 稳定但 token 信用稀疏。RLSD 虽用 A_{ORM} 定方向, 幅度仍被 style 污染。

2.4 例子

token Wait 在正确与错误 hint 下都因“干脆风格”被打压, 相减后 style 对消, $|e_{ctr}|$ 的 top token 更多是 3/sqrt/factor。单条误差类型不匹配的负 hint 会使 e_{ctr} 符号随机, 故需 K -marginalize。

3 方法论树状拆解

RLCSD

```
|-- Stage1 采样 G=8, 划分 G+/G-, 算 A_ORM
|-- Stage2 正 hint (主实验 GT CoT) vs K=4 负 sibling
|   同模板; 排除当前 y
|   ectr = log piT(yc*) - log( (1/K) sum piT(yw,k*) )
`-- Stage3 rt=lambda tanh(ectr/tau); mask; sign clamp; two-path PPO
```

4 算法流程与公式细节推演

最终对比信号 (paper Eq. (7)), 先对负支概率平均再取对数:

$$e_{\text{ctr},t} = \log \pi_T(y_t | x, y_c^*, y_{<t}) - \log \left(\frac{1}{K} \sum_{k=1}^K \pi_T(y_t | x, y_{w,k}^*, y_{<t}) \right). \quad (2)$$

调制 (paper Eq. (9)–(11)):

$$r_t = \lambda \tanh(e_{\text{ctr},t}/\tau), \quad (3)$$

$$m_t = \mathbf{1}(|r_t| > \delta), \quad (4)$$

$$\tilde{A}_t = \begin{cases} \max(0, A_{\text{ORM}} + r_t) & A_{\text{ORM}} \geq 0, \\ \min(0, A_{\text{ORM}} + r_t) & A_{\text{ORM}} < 0. \end{cases} \quad (5)$$

PDF 口径: $\tau = 0.02$, $\lambda = 0.5$, $\delta = 0.02$, $\eta = 1.0$, $K = 4$ 。Two-path (paper Eq. (15)) 对未调制集 U 与调制集 M 分别平均, 否则 20%–30% 的 M 会被全局平均稀释。

手算: $A_{\text{ORM}} = +1$, $e_{\text{ctr}} = 0.04$, 则 $r = 0.5 \tanh(2) \approx 0.482$, $\tilde{A} = 1.482$ 。若 e_{ctr} 极负, clamp 仍保持 $\tilde{A} \geq 0$ 。

5 实验设定与资源开销

对照 GRPO、OPSD、SDPO、SRPO、RLSD。8×H20 全参, veRL+FS DP2+vLLM。 $G = 8$, train 最大 16384, eval 38912。数学 lr 1×10^{-6} ; 逻辑 RLCS D 用 5×10^{-6} , 其它方法用 1×10^{-6} (不完全对齐)。教师: RLCS D 每 10 step snapshot。4B 数学 step time (Table 9): RLCS D 总 891.55s, 教师 logprob 14.21s, 快于 OPSD/SDPO/SRPO 的 dense 蒸馏。

6 实验结论的因果支撑

主表几乎全列最优。Qwen3-8B: Math Avg 79.3, KK Avg 74.0 (Base 为 76.6/59.6)。OOD 11-role 相对 Base +21.0。训练曲线: RLCS D 接近 GRPO 的稳定, 且验证更好 (强支撑)。插件实验: 单侧换 GT→self 几乎不变; 加上 contrast 普遍提升; 去掉 contrast 的 RLCS D 掉点最大。组件消融: 去掉 A_{ORM} 锚定跌得最多; 附录 A 显示 dissimilar 负 hint 的 wrong-sign 约 51%, K -marginal 后 < 8%。外部 OPD 诊断: 更强但文风远的 Instruct 教师蒸馏更差。限制: 逻辑 lr 不对齐; 无多种子; README 数字/超参与 PDF 不完全一致。

7 复现前置准备清单

- 数据: `python scripts/download_data.py --all` (Leyiii/RLCS D)。
- 权重: Qwen3 与 Olmo-3-7B-Think。
- 硬件: 论文 8×H20。
- 配置按 PDF: $\tau = 0.02$, $\eta = 1.0$, snapshot 每 10 step。
- Sanity: $A_{\text{ORM}} > 0$ 时 $\tilde{A}$ 不得为负; 空 G^+ 或 G^- 应 skip。

8 Paper 与代码缺口 / 开放问题

PDF Table 8 与 GitHub README 在教师是否固定、 τ/η 、主表数字上不一致。损失注册于 `core_algos.py` 的 `rlcsd`。开放：逻辑表的 lr 公平性；把 `task/style` 诊断做成训练门。