

组会汇报：TGOPD (Verify Before You Distill)

Paper Read Skill

2026 年 9 月 17 日

目录

1	一句话贡献	2
2	任务定义与动机剖析	2
2.1	任务	2
2.2	问题与动机	2
2.3	现有局限	2
2.4	例子	2
3	方法论树状拆解	2
4	算法流程与公式细节推演	3
5	实验设定与资源开销	3
6	实验结论的因果支撑	3
7	复现前置准备清单	4
8	Paper 与代码缺口 / 开放问题	4

论文: AllSpark Team. *Verify Before You Distill: Prompt-Level Teacher Gating for On-Policy Distillation*. arXiv:2609.02998v1. PDF: docs/7_TGOPD.pdf。框架: slime 异步栈。截至整理时未见官方代码仓。

1 一句话贡献

Vanilla OPD 对每个 prompt 无条件使用教师 token 级 reverse-KL。TGOPD 先用 $K_T = 3$ 次教师探针与验证器 pass rate 做 prompt 级可靠性审计: 通过则走稠密 OPD, 否则撤回教师、改走验证器 grounding 的 GRPO。门是硬路由而不是插值。

2 任务定义与动机剖析

2.1 任务

后训练 On-Policy Distillation: 学生 π_θ 自己采样, 冻结域专家教师 π_T 给 token 级 reverse-KL。学生为 Qwen3.5-4B 与 Qwen3.6-35B-A3B; 域为数学、代码、指令遵循。教师由同一基座 GRPO 得到后冻结。另有 MOPD: 单学生三域, prompt 先路由域教师再套门。

2.2 问题与动机

Reverse KL 是 mode-seeking: 教师在某题上自信地错, 会把学生强推到错误模式。熵或师生 likelihood 一致测的是不确定, 不是对错。异步部署中教师只做 scoring forward, 必须等学生 decode, 4B 单域教师节点利用率仅 9.8%, 59% 时间低于 5%。动机: 用空窗生成探针, 用验证器得到 $q_T(x)$, 再决定是否准入稠密 OPD。

诊断 (每 prompt 10 条离线教师样本): 代码域自信 AUROC 0.51, 数学 0.73; 低可靠性区教师最高自信样本仍错 (代码 84%, 数学 61%)。

2.3 现有局限

EOPD / TrOPD / REOPOLD 停在分布侧; RG-OPD / SPOT 做轨迹或 token 局部筛选; RLSD-style 对所有 prompt 削弱教师; MOPD 按域路由后仍无条件使用稠密奖励。

2.4 例子

三次探针奖励 $(0, 0, 1)$ 则 $q_T = 1/3 < \tau = 2/3$, 门关, 即使教师对错误 token 的 $\log \pi_T$ 很高也不进梯度。学生 1 对 3 错时 GRPO 仍给相对更好的轨迹正优势。三次探针 2 过则整段走 OPD, 验证器不进该 prompt 的梯度。

3 方法论树状拆解

创新在 prompt 级硬路由与空窗探针, 不在 OPD/GRPO 公式本身。

TGOPD

|-- A 教师可靠性探针 (填空窗)

```

|      RT(x)=E[r]; qT = KT 次 pass 均值; KT=3, tau=2/3
|-- B 硬门 g=1[qT >= tau]
|      开: token A_OPD; 关: 轨迹 A_GRPO (无 std 归一)
`-- C PPO-clip; IcePop/TIS 为异步共享修正

```

4 算法流程与公式细节推演

OPD 优势 (paper Eq. (1)) 与验证器无关:

$$\hat{A}_{i,t}^{\text{OPD}} = \beta \text{sg} \left[\log \pi_T(y_i^t | x, y_i^{<t}) - \log \pi_\theta(y_i^t | x, y_i^{<t}) \right]. \quad (1)$$

GRPO 组内均值中心化、广播到所有 token (paper Eq. (2)):

$$\hat{A}_i^{\text{GRPO}} = r(x, y_i) - \frac{1}{G} \sum_{j=1}^G r(x, y_j), \quad \hat{A}_{i,t}^{\text{GRPO}} = \hat{A}_i^{\text{GRPO}}. \quad (2)$$

可靠性与门 (paper Eq. (3)–(5)):

$$R_T(x) = \mathbb{E}_{y \sim \pi_T} [r(x, y)], \quad (3)$$

$$q_T(x) = \frac{1}{K_T} \sum_{k=1}^{K_T} r(x, \hat{y}_k), \quad g(x) = \mathbf{1}[q_T(x) \geq \tau]. \quad (4)$$

选择器而非插值 (paper Eq. (6)):

$$\hat{A}_{i,t}^{\text{TGOPD}} = g(x) \hat{A}_{i,t}^{\text{OPD}} + (1 - g(x)) \hat{A}_{i,t}^{\text{GRPO}}. \quad (5)$$

再进入 PPO-clip (paper Eq. (7)). $K_T q_T \sim \text{Binomial}(K_T, R_T)$, 估计无偏。组内奖励全相同则 GRPO 优势为 0。

手算: $G = 4, K_T = 3, \tau = 2/3$ 。门开时 $\log \pi_T - \log \pi_S = 0.8$ 则该 token 优势为 0.8。门关且学生奖励 (1, 0, 0, 0) 则优势 (+0.75, -0.25, -0.25, -0.25) 广播。

35B CodeIO 对齐 500 cycle: 平均 step time +5.9%, decode 吞吐变化 < 0.1%。空闲填满不等于零墙钟。

5 实验设定与资源开销

对照: Vanilla OPD、TrOPD、RG-OPD、RLSD-style (外部冻结教师缩放幅度)。数据: DAPO-Math-17K; CodeI/O; Nemotron-Cascade 2 过滤 IF。评测: AIME 2025/2026 avg@64, HMMT-Feb avg@32, LCB pass@1 avg@6, OJBench, IFBench/IFEval。超参: rollout batch 64, $G = 4$, update batch 128, $\text{lr } 1 \times 10^{-6}$, PPO $\epsilon = 0.2$, 数学最大回复 16384。硬件: 4B 为 5×8 GPU; 35B 为 7×8 GPU。4B SOPD 教师利用率 9.8% $\rightarrow$ 78.9%, 集群 51.5% $\rightarrow$ 69.5%。

6 实验结论的因果支撑

全部六个单域设定 TGOPD 优于 Vanilla OPD, 代码增益最大, 与自信最不能预测对错一致 (强支撑)。35B LCB 上其它蒸馏方法负迁移, 仅 TGOPD 正迁移并超过教师。RLSD-style 在 14

列中 8 列低于 base：均匀削弱教师有害（强支撑）。MOPD 七基准平均 4B $53.40 \rightarrow 54.54$, 35B $60.99 \rightarrow 61.94$ （中强支撑）。 τ sweep 呈倒 U，峰在 3/5，靠近默认 2/3。关门后 mask 已能解释约 90% 增益，GRPO fallback 额外一点。限制：无多种子；必须有自动验证器；门为二值。

7 复现前置准备清单

- 数据：DAPO-Math-17K、CodeI/O、过滤后的 Cascade IF。
- 权重：Qwen3.5-4B / Qwen3.6-35B-A3B；三域 GRPO 教师需自训。
- 硬件：完整 4B SOPD 约 40 张 80GB 级卡；无官方仓。
- 必做：探针 q_T 、硬门、OPD/GRPO 互斥、GRPO 无 std 归一。
- Sanity： $\tau = 0$ 接近 Vanilla OPD；常数组奖励时 $g = 0$ 梯度为 0。

8 Paper 与代码缺口 / 开放问题

无官方代码与 TeX 仓。 β 未扫。IcePop 不是方法贡献。开放：软门、无验证器任务、按域切换关门策略。